

AlphaGo

Masterizando Go Através da Inteligência Artificial

Introdução

AlphaGo é um software de IA desenvolvido pela [Google DeepMind](#), e é tido como um dos exemplos mais influentes da aplicação de redes neurais em problemas reais e difíceis. Isso porque, por muitos anos, pensou-se que jogo de estratégia Go fosse “*AI-resistant*”, dada a sua grande complexidade.

O triunfo desse software se deu quando sua capacidade foi posta à prova numa série de partidas, ocorridas em 2016, contra o jogador profissional [Lee Sedol](#) (18 vezes campeão mundial e amplamente considerado o maior jogador de Go daquela década), onde o AlphaGo foi campeão por um placar de 4-1.

O que é Go?

Um jogo de tabuleiro de estratégia, jogado por 2 jogadores. Seu objetivo é simples: cercar e controlar o maior território possível no tabuleiro. Diferente do xadrez, o foco não é eliminar ou capturar o líder adversário, mas acumular mais pontos que o oponente ao final da partida através de áreas dominadas e pedras capturadas.

Sua origem é chinesa, datada há mais de 2500 anos, tido como o jogo de tabuleiro mais antigo ainda jogado na atualidade.

Desafios

Apesar de ser simples nas regras, é altamente complexo na prática, porque:

- O tamanho do tabuleiro é 19x19, oferecendo um leque de configurações equivalente a 10^{170} – um valor maior do que o número de átomos no universo (o xadrez por sua vez, possui um leque equivalente a 10^{47}).
- É muito difícil escrever uma função de validação eficaz para uma jogada no Go. Um forte senso de “bom tabuleiro” no Go é puramente humano e intuitivo, não facilmente baseado em regras.
- Busca por força bruta, que havia funcionado para o xadrez através do [Deep Blue](#), da IBM, se mostrou computacionalmente ineficiente para o Go.

Arquitetura do AlphaGo

O AlphaGo combinou *Monte Carlo Tree Search* (MCTS) com *Deep Neural Networks* através de duas redes principais:

- **Policy Network:** Treinada para predição, dada a disposição do tabuleiro, responsável por indicar qual seria a possível próxima jogada do oponente. Isso otimizou a busca pelas melhores jogadas ao invés de considerar todos os possíveis movimentos.
- **Value Network:** Treinada para estimar a probabilidade de vitória dada uma posição no tabuleiro, eliminando a necessidade de simular partidas inteiras.

Metodologia

O treinamento das redes se deu, basicamente, em 2 estágios:

- **Supervised Learning:** Utilizou aproximadamente 30 milhões de partidas jogadas por profissionais para ensinar a Policy Network a imitar o comportamento humano.
- **Reinforcement Learning:** A rede neural jogou contra ela mesma em suas versões iniciais, visando melhorar o panorama para além da capacidade humana.

Por fim, todo esse esforço foi utilizado para guiar a MCTS, fazendo a árvore drasticamente mais eficiente por focar o esforço computacional em buscas por jogadas com maior probabilidade de vitória.

Relevância

Com o AlphaGo, foi possível demonstrar que Deep Learning é capaz de capturar um tipo de padrão de reconhecimento e intuição que antes era considerado impossível computacionalmente. Seu sucessor, [AlphaGo Zero](#) (2017), foi mais além: aprendeu puramente do zero, apenas jogando contra si mesmo, sem utilizar dados de partidas humanas.

Essas conquistas levaram a outras abordagens, originando o [AlphaZero](#), que masterizou xadrez e [shogi](#). Posteriormente possibilitou outros avanços científicos, como o [AlphaFold](#) (utilizado para predição de estruturas de proteínas).

Referências

- [Research - AlphaGo](#)
- [Go \(game\)](#)
- [AlphaGo - The Movie](#)